

Ewerton Silva

Engenheiro de IA · Sistemas com LLM, Agentes e Avaliação

ewertoncom297@gmail.com | github.com/Ewertonslv | linkedin.com/in/ewertonslv | ewertonslv.github.io | Caicó, RN · Remoto

RESUMO

Engenheiro de software com 4+ anos entregando sistema em produção, hoje focado em aplicações baseadas em LLM: agentes, MCP e medição de qualidade. Trago para o mundo de LLM a disciplina de software fiscal regulado, onde um bug vira multa: Python e FastAPI, orquestração multi-agente na Claude API, serverless na AWS, e teste automatizado com CI em todo projeto que publico. Escrevi uma ferramenta pública que mede o recall de guardrails de prompt-injection contra dataset rotulado, e tenho correção mergeada no BerriAI/litellm. Prefiro colocar número no que construo a supor que está funcionando.

COMPETÊNCIAS

Linguagens	Python, TypeScript, JavaScript, SQL, Delphi
IA / LLM	Claude API, AWS Bedrock, sistemas multi-agente, MCP, RAG, busca vetorial e embeddings, engenharia de prompt, guardrails, avaliação com dataset rotulado (recall, precisão, F1)
Backend	FastAPI, Node.js, Fastify, REST, WebSockets
Dados	PostgreSQL, SQLite, sqlite-vec, Prisma, Redis, SQL
Cloud / DevOps	AWS (Lambda, Step Functions, DynamoDB, Bedrock, API Gateway, SAM), Docker, GitHub Actions, Git
Engenharia	Testes unitários e de integração (pytest, Vitest), CI/CD, Clean Code, design patterns, revisão de código
Frontend	React, Next.js, Tailwind CSS, React Native

EXPERIÊNCIA

Engenheiro de Software · Viggo Sistemas 2022 · atual
ERP de varejo certificado GPTW (fundado em 2009) · PDV, fiscal e pagamentos para 5.000+ varejistas em 16 estados.

- Construí do zero o módulo de controle de entregas, com painel kanban para acompanhar o pedido pelas etapas de expedição.
- Liderei boa parte de uma migração de 10 meses que unificou a lógica de venda de PDV e Pedido e aposentou módulos legados inteiros.
- Projetei e construí do zero um sistema de analytics de uso: rastreador no cliente, API autenticada própria (Horse/Delphi) e modelo de contadores agregados em PostgreSQL, com upsert e fila local à prova de queda de rede. A decisão de manter ou remover uma tela passou a sair de dado de uso real, não de achismo.
- Trabalho diário no domínio fiscal brasileiro: NF-e, NFC-e, MDF-e, SPED e a reforma CBS/IBS. É um ambiente onde erro custa dinheiro do cliente, e isso moldou como eu testo.
- Construo ferramentas internas de IA sobre a Claude API, com squads multi-agente e automação do fluxo de desenvolvimento, enquanto o time migra de Delphi para desenvolvimento assistido por IA.
- Sou responsável pelo banco PostgreSQL de produção: 700+ tabelas (produtos, participantes, fiscal, pedidos), triggers e stored procedures.

PROJETOS

guardrail-bench · mede o recall de um filtro de prompt-injection contra dataset público rotulado (deepset/prompt-injections, 662 mensagens: 263 ataques e 399 legítimas). Roda qualquer callable Python, reporta recall, precisão, F1 e matriz de confusão, lista os ataques que passaram, e quebra o build abaixo do limiar escolhido. Nasceu de um resultado ruim meu: um filtro por regex que eu já tinha colocado na frente de um modelo pegava 15,6% dos ataques, e eu nunca tinha medido. 48 testes. Python · Hugging Face datasets · CLI · repositório público.

recepia · SaaS multi-tenant que agenda e confirma consultas por WhatsApp, com classificação de intenção por LLM, guardrail de prompt-injection (OWASP LLM01), mascaramento de PII e observabilidade de custo e latência por requisição. 223 testes automatizados e CI no GitHub Actions. No ar em [recepia.app.br](#), código aberto no GitHub. Python · FastAPI · PostgreSQL · LLM · LGPD.

liveaula · plataforma de educação para aulas particulares, com três clientes sobre um contrato tipado único: o professor registra a aula em menos de 30 segundos, o responsável recebe push e acompanha a evolução do aluno, e um admin supervisiona tudo. Schemas Zod compartilhados fazem mudança de contrato virar erro de tipo nos três apps em vez de bug em runtime. CI e deploy automatizados. TypeScript · Next.js 14 · Fastify · Prisma · PostgreSQL · React Native (Expo).

scout · pipeline serverless de pesquisa multi-agente na AWS: Step Functions distribui o trabalho entre agentes Lambda sobre Bedrock (planner, workers, crítico, sintetizador), com o crítico avaliando a saída antes da síntese. Também exposto como servidor MCP. Infraestrutura como código e deploy por OIDC. AWS Lambda · Step Functions · DynamoDB · Bedrock · SAM · GitHub Actions.

Monarch-IA · plataforma de orquestração de 12 agentes na Claude API, com portões de aprovação humana e circuit breakers para conter agente em loop ou custo fora da curva. Python · Claude API · Docker.

brain-pessoal (projeto pessoal, repositório privado) · servidor MCP de memória com busca híbrida, combinando similaridade vetorial e palavra-chave sobre banco vetorial local (sqlite-vec) com embeddings gerados na própria máquina (fastembed), sem chamada externa. Python · fastmcp · sqlite-vec · fastembed.

evolution-whatsapp-mcp · servidor MCP open-source que expõe o WhatsApp como ferramentas para qualquer cliente MCP. Publicado no npm. TypeScript · MCP SDK.

OPEN SOURCE

- **BerriAI/litellm** (gateway de LLM) · corrigi um bug silencioso de cálculo de custo: faixas de preço customizadas acima de limiares não padronizados eram descartadas em `get_model_info`, e a cobrança caía para a tarifa base sem avisar ninguém. Enviei a correção com teste de regressão; revisada e mergeada pelos mantenedores (#30880).
- Contribuições em análise em **bentoml/BentoML** e **IBM/mcp-context-forge**.

FORMAÇÃO

Sistemas de Informação · UFRN

desde 2017

Universidade Federal do Rio Grande do Norte · Todas as disciplinas concluídas; TCC pendente.

IDIOMAS

Português nativo. Inglês com leitura e escrita técnicas sólidas, de uso diário em documentação, papers, código e pull requests em projetos internacionais. Conversação ainda limitada, em prática ativa.